

Arquitectura DenseNet

A arquitectura **DenseNet** (neste caso DenseNet121 (*)), foi a que apresentou melhores resultados.

(*) 121 camadas profundas, adequada a datasets médicos porque consegue:

- preservar detalhes finos;
- reutilizar características importantes;
- aprender padrões subtis.

Existem variantes DenseNet169, 201, etc.

Como o dataset era relativamente pequeno, a baseline já utilizava transfer learning com pesos pré-treinados no ImageNet. E recorreu a Focal Loss, scheduler de learning rate e early stopping, funcionando como uma baseline sólida para classificação médica. No entanto, os resultados ainda eram bastante afectados pelo desequilíbrio do dataset e pelo risco de overfitting.

- Transfer Learning: Com pesos treinados no ImageNet
- Focal Loss: Função de loss criada para problemas com desequilíbrio de classes. Dá mais importância às amostras difíceis.
- Scheduler de learning rate: Mecanismo que ajusta automaticamente o learning rate durante o treino.
- Early stopping: Técnica que interrompe o treino quando o modelo deixa de melhorar durante X épocas.

Com o objectivo de melhorar o F1-score macro, começamos por pequenos ajustes, apenas para perceber o impacto dos mesmos no desempenho do modelo. Contudo, já havíamos percebido que seria necessário adoptar estratégias específicas para mitigação do desequilíbrio das classes. As versões v99 e v100 surgem nesse sentido, sendo a v100 = v99 + CLAHE.

v100

preprocessamento CLAHE aplicado ao dataset original.

com o objectivo clínico de melhorar:

- contraste local;
- deteção de detalhes finos;
- robustez em estruturas anatómicas pouco visíveis.

Optimizador: AdamW

Adam - Optimizador baseado em gradiente que combina: Momentum e RMSProp. Muito utilizado em Deep Learning devido à sua estabilidade e rapidez de convergência. AdamW - Versão melhorada do Adam que separa o weight decay da atualização dos pesos, ajudando a reduzir overfitting.

Scheduler: OneCycleLR

Scheduler que altera dinamicamente o learning rate ao longo do treino. Pode melhorar convergência e generalização.

Loss Functions

Combinação de:

- Focal Loss - Função de loss criada para problemas com desequilíbrio de classes. Dá mais importância às amostras difíceis.
- CrossEntropy - Função de loss muito utilizada em classificação multi-classe. Mede a diferença entre previsão do modelo e classe correta.
- class weights - Pesos atribuídos às classes para compensar desequilíbrio das classes. Classes raras recebem maior importância na loss.
- label smoothing - Técnica que suaviza os labels para evitar excesso de confiança do modelo. Em vez de 0 e 1 usa 0.09 e 0.91.

Regularização

Regularização - Conjunto de técnicas utilizadas para reduzir overfitting.

- Mixup augmentation - Criar novas imagens/amostras misturando duas imagens reais e também misturar labels.

Data Augmentation (durante o treino do modelo)

Data Augmentation - Técnica usada durante o treino para aumentar artificialmente a diversidade do dataset.

Augmentações mais agressivas:

- flips horizontais e verticais;
- rotações;
- alterações de intensidade;
- zoom e transformações espaciais.

Inferência (durante o teste do modelo/predict)

- Test-Time Augmentation (TTA) - Técnica utilizada durante a inferência para tornar as previsões do modelo mais robustas e estáveis. Várias versões da mesma imagem durante o teste.
- Threshold tuning por classe - Técnica usada para ajustar o limiar de decisão do modelo. Assume valor diferente por classes porque a previsão de algumas (classes) são mais difíceis do que outras, então esta técnica serve para evitar, por exemplo, não considerar casos reais de doença por não atingir um eventual Threshold definido "às cegas".

Objetivo técnico

- combater desequilíbrio das classes;
- reduzir overfitting;
- melhorar recall das classes minoritárias.

A combinação destas estratégias permitiu atingir um F1-score macro de 0.7076 no conjunto de teste.

Tabela Resumo

Versão	Principais melhorias	Input Size	Batch Size	Estratégias principais	F1-score macro
v0	Baseline inicial	512×512	4	Pipeline base DenseNet	0.5466
v1	Redução resolução + batch maior	224×224	16	Melhor estabilidade e velocidade	0.5910
v2	Introdução de CLAHE	512×512	4	Melhor contraste médico	0.6385
v3	CLAHE + resolução reduzida	224×224	16	Otimização computacional	0.5515
v99	F1Boost	512×512	8	AdamW, OneCycleLR, Mixup, TTA	0.6467
v100	v99 + CLAHE	256×256	16	AdamW, OneCycleLR, Mixup, TTA + CLAHE	0.7076

Conclusão

A evolução do projecto demonstrou que pequenas alterações arquitecturais e de optimização podem produzir ganhos significativos em tarefas de classificação médica.

As versões mais avançadas integraram técnicas modernas de pré-processamento, regularização, optimização e inferência, permitindo melhorar significativamente o desempenho do modelo em cenários de desequilíbrio de classes.