

Evolução do Modelo DenseNet — v0 até v100

Contexto

Este documento resume a evolução do modelo DenseNet utilizado para classificação automática de imagens ERCP em quatro classes clínicas:

- Biliary_Leaks
- Lithiasis
- Normal
- Stricture

A evolução foi construída de forma incremental, testando alterações em:

- resolução das imagens;
- batch size;
- pré-processamento;
- data augmentation;
- loss functions;
- schedulers;
- regularização;
- estratégias de inferência.

Nota: apenas foram disponibilizadas as versões v0, v1, v2, v3, v99 e v100.

As versões intermédias (v4 → v98) não estavam presentes nos notebooks enviados.

v0 — Baseline inicial

Objetivo

Criar a primeira baseline funcional utilizando DenseNet para classificação multi-classe.

Configuração principal

- Input size: 512×512
- Batch size: 4
- Epochs: 60
- Learning rate: 1e-4

Características

- Pipeline base MONAI
- Aumentações simples
- Scheduler básico
- Sem otimizações avançadas
- Sem técnicas específicas para imbalance

Resultado

A versão v0 serviu como referência inicial para todas as experiências posteriores.

F1-score macro

≈ **0.5466**

v1 — Otimização de dimensão e batch

Alterações introduzidas

- Redução da resolução:
 - $512 \times 512 \rightarrow 224 \times 224$
- Aumento do batch size:
 - $4 \rightarrow 16$

Objetivo

Melhorar:

- velocidade de treino;
- estabilidade dos gradientes;
- utilização de memória;
- generalização do modelo.

Impacto esperado

- treino mais rápido;
- maior estabilidade;
- menor overfitting.

F1-score macro

≈ **0.5910**

v2 — Introdução de CLAHE

Alterações introduzidas

Foi introduzido:

- CLAHE (Contrast Limited Adaptive Histogram Equalization)

Objetivo

Melhorar:

- contraste local;
- visibilidade de estruturas clínicas;
- robustez em imagens médicas.

Configuração CLAHE

- clipLimit = 2.0
- tileGridSize = (8,8)
- probabilidade = 0.7

Resultado

Esta versão apresentou uma melhoria significativa do desempenho global.

F1-score macro

≈ **0.6385**

v3 — CLAHE + otimização de resolução

Alterações introduzidas

Combinação de:

- CLAHE da v2
- resolução reduzida para 224×224
- batch size aumentado para 16

Objetivo

Combinar:

- melhor contraste;
- treino mais rápido;
- melhor estabilidade.

Observações

Apesar da melhoria computacional, o ganho de F1 não foi superior ao da v2.

F1-score macro

≈ **0.5515**

v99 — F1Boost

Objetivo

Criar uma versão fortemente otimizada para maximizar F1-score macro.

Principais melhorias

Otimizador e Scheduler

- AdamW
- OneCycleLR

Loss Functions

Combinação de:

- Focal Loss
- CrossEntropy
- class weights
- label smoothing

Regularização

- Mixup augmentation

Data Augmentation

Augmentações mais agressivas:

- flips horizontais e verticais;
- rotações;
- alterações de intensidade;
- zoom e transformações espaciais.

Inferência

- Test-Time Augmentation (TTA)
- Threshold tuning por classe

Objetivo técnico

- combater class imbalance;
- reduzir overfitting;
- melhorar recall das classes minoritárias.

F1-score macro

≈ **0.5196**

v100 — v99 + CLAHE

Objetivo

Combinar:

- toda a pipeline avançada da v99;
- pré-processamento CLAHE aplicado ao dataset original.

Melhorias herdadas da v99

- AdamW
- OneCycleLR
- Mixup
- Focal Loss
- Label smoothing
- TTA
- Threshold tuning
- Aumentações agressivas

Nova melhoria

- CLAHE integrado diretamente no pré-processamento

Objetivo clínico

Melhorar:

- contraste local;
- detecção de detalhes finos;
- robustez em estruturas anatómicas pouco visíveis.

Configuração principal

- Input size: 256×256
- Batch size: 16
- Epochs: 80
- Learning rate: 3e-4

Observações

A v100 representa a versão mais avançada da pipeline DenseNet disponível nos notebooks fornecidos.

F1-score macro

Não identificado diretamente nos outputs do notebook disponibilizado.

Evolução Global do Projeto

Principais tendências observadas

1. Otimização computacional

A redução da resolução e o aumento do batch size permitiram:

- treino mais rápido;
- maior estabilidade;
- melhor aproveitamento do hardware.

2. Melhorias de préprocessamento

O CLAHE mostrou impacto relevante na melhoria do contraste em imagens médicas.

3. Estratégias anti-overfitting

Foram adicionadas:

- Mixup;
- augmentações agressivas;
- label smoothing;
- regularização via AdamW.

4. Otimização para F1-score

As versões mais avançadas focaram-se explicitamente em:

- class imbalance;
- aumento do recall;
- melhoria do F1-score macro.

5. Inferência avançada

A utilização de:

- TTA;
- threshold tuning; permitiu melhorar robustez e estabilidade da classificação final.

Tabela Resumo

Versão	Principais melhorias	Input Size	Batch Size	Estratégias principais	F1-score macro
v0	Baseline inicial	512×512	4	Pipeline base DenseNet	0.5466
v1	Redução resolução + batch maior	224×224	16	Melhor estabilidade e velocidade	0.5910
v2	Introdução de CLAHE	512×512	4	Melhor contraste médico	0.6385
v3	CLAHE + resolução reduzida	224×224	16	Otimização computacional	0.5515

Versão	Principais melhorias	Input Size	Batch Size	Estratégias principais	F1-score macro
v99	F1Boost	512×512	8	AdamW, OneCycleLR, Mixup, TTA	0.6467
v100	v99 + CLAHE	256×256	16	Pipeline avançada + CLAHE	0.7076

Conclusão

A evolução do projeto demonstrou uma abordagem iterativa orientada à melhoria do desempenho em classificação médica.

As principais contribuições ao longo das versões foram:

- pré-processamento especializado;
- regularização avançada;
- técnicas modernas de otimização;
- estratégias focadas em class imbalance.