

Léxico de Aprendizagem Profunda (Deep Learning)

1. Redes Neurais e CNNs

CNN (Convolutional Neural Network)

Rede neuronal especializada em processamento de imagens.

DenseNet

Arquitetura de CNN onde cada camada recebe informação de todas as camadas anteriores.

Vantagens:

- reutilização de características;
- menor perda de informação;
- melhor fluxo de gradientes.

Convolution

Operação matemática central das CNNs utilizada para extrair características das imagens (bordas, texturas, etc.).

Weights

Parâmetros internos aprendidos pela rede neuronal durante o treino.

Forward Pass

Passagem dos dados pela rede para produzir previsões.

Backpropagation

Algoritmo utilizado para atualizar os pesos da rede neuronal com base no erro calculado.

Gradient

Valor matemático que indica como ajustar os pesos para minimizar o erro.

2. Treino do Modelo

Hyperparameters

Parâmetros definidos manualmente antes do treino.

Exemplos:

- learning rate: controla o tamanho das atualizações dos pesos durante o treino.
- batch size: número de imagens processadas de cada vez;
- epochs.

Loss Function

Função matemática utilizada para medir o erro do modelo.

CrossEntropy Loss

Função de loss muito utilizada em classificação multi-classe.

Mede a diferença entre:

- previsão do modelo;
- classe correta.

Focal Loss

Função de loss criada para problemas com desequilíbrio de classes.

Dá mais importância às amostras difíceis.

Optimizer

Algoritmo responsável por atualizar os pesos da rede neuronal.

Exemplos:

- SGD;
- Adam;
- AdamW.

SGD (Stochastic Gradient Descent)

Otimizador clássico baseado em gradiente.

Adam

Otimizador baseado em gradiente que combina:

- Momentum;
- RMSProp.

Muito utilizado em Deep Learning devido à sua estabilidade e rapidez de convergência.

AdamW

Versão melhorada do Adam que separa o weight decay da atualização dos pesos, ajudando a reduzir overfitting.

Scheduler

Mecanismo que ajusta automaticamente o learning rate durante o treino.

OneCycleLR

Scheduler que altera dinamicamente o learning rate ao longo do treino. Pode melhorar convergência e generalização.

Callback

Função executada automaticamente durante o treino.

Exemplos:

- guardar melhor modelo;
- early stopping;
- logging.

Checkpoint

Ficheiro guardado contendo:

- pesos do modelo;

- estado do treino;
- métricas.

Permite continuar ou recuperar treinos.

Early Stopping

Técnica que interrompe o treino quando o modelo deixa de melhorar.

3. Métricas de Avaliação

Metrics

Indicadores utilizados para avaliar o desempenho do modelo.

Exemplos:

- accuracy;
- precision;
- recall;
- F1-score.

Accuracy

Percentagem de previsões corretas realizadas pelo modelo relativamente ao total de amostras.

Precision

Métrica que mede quantas previsões positivas estavam corretas.

Fórmula: $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$

Recall

Métrica que mede quantos casos positivos reais foram corretamente identificados.

Fórmula: $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$

F1-score

Métrica que combina:

- precision;
- recall.

Muito útil em datasets desbalanceados.

Fórmula: $F1 = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$

F1-score Macro

Média do F1-score calculado individualmente para todas as classes.
Todas as classes têm o mesmo peso.

Macro Average

Média simples calculada igualmente para todas as classes.

AUC (Area Under the Curve)

Métrica que mede a capacidade de separação entre classes.
Quanto mais próximo de 1, melhor o desempenho.

Confusion Matrix

Tabela que compara:

- valores reais;
- previsões do modelo.

Permite analisar erros de classificação.

4. Preprocessamento e Data Augmentation

Preprocessing

Transformações realizadas antes do treino.

Exemplos:

- resize;

- normalização;
- CLAHE.

Resize

Alteração da resolução da imagem.

Normalization

Processo de normalização dos valores da imagem.
Ajuda a estabilizar o treino.

CLAHE

Contrast Limited Adaptive Histogram Equalization.
Técnica de melhoria de contraste em imagens médicas.

Melhora:

- contraste local;
- visibilidade de detalhes anatómicos.

Augmentation (Data Augmentation)

Técnicas de transformação artificial das imagens para aumentar a variabilidade do dataset.

Exemplos:

- rotação;
- flip;
- zoom;
- alteração de brilho;
- crop.

Objetivo:

- reduzir overfitting;
- melhorar generalização.

Mixup

Técnica de augmentation que mistura imagens e labels.
Ajuda na generalização.

TTA (Test-Time Augmentation)

Aplicação de augmentações durante a inferência.

Objetivo:

- aumentar robustez;
- melhorar estabilidade das previsões.

5. Regularização e Generalização

Overfitting

Situação em que o modelo aprende demasiado bem os dados de treino, mas falha em generalizar.

Regularization

Conjunto de técnicas utilizadas para reduzir overfitting.

Exemplos:

- dropout;
- weight decay;
- augmentation.

Dropout

Técnica de regularização que desativa neurónios aleatoriamente durante o treino.
Ajuda a reduzir overfitting.

Weight Decay

Técnica de regularização que penaliza pesos muito elevados.

Label Smoothing

Técnica que suaviza os labels para evitar excesso de confiança do modelo.

Threshold Tuning

Ajuste do limiar de decisão utilizado para classificação.
Pode melhorar F1-score e recall.

Desequilíbrio das Classes

Situação em que algumas classes possuem muito mais exemplos do que outras.
Pode prejudicar o treino do modelo.

Class Weights

Pesos atribuídos às classes para compensar desequilíbrio das classes.
Classes raras recebem maior importância na loss.

6. Transfer Learning e Fine-Tuning

Transfer Learning

Utilização de modelos pré-treinados em novos problemas.

Fine-Tuning

Ajuste de um modelo pré-treinado para um novo problema específico.