

Classificação de Imagens ERCP com Redes Neurais Convolucionais Profundas

Comparativo: DenseNet121 ▪ ResNet50 ▪ MobileNetV2 ▪ EfficientNet-B7

C. Bergueira D. Silva F. Pereira R. Rodrigues

Universidade do Minho — Grupo 8

Aprendizagem Profunda - Módulo 2 - 2025/2026

2026

Problema: Classificação Automática de ERCP

Contexto clínico

- ERCP: fluoroscopia para diagnóstico biliar/pancreático
- Interpretação manual é demorada e especializada
- Objetivo: sistema CADx de apoio à decisão

Dataset MIQR-CC (Martins et al., 2025)

Classe	Treino	Val	Teste
Biliary Leaks	110 (10%)	24	17
Lithiasis	505 (47%)	98	123
Normal	197 (18%)	59	43
Stricture	255 (24%)	53	84
Total	1067	234	267

Desafio central: desequilíbrio

47% Lithiasis **vs.** 10% Biliary Leaks

Um modelo que ignore BL alcança accuracy alta mas é **fortemente penalizado** pela métrica.

Métrica: F1-Score Macro

$$F_1^{\text{macro}} = \frac{1}{4} \sum_{c=1}^4 \frac{2 P_c R_c}{P_c + R_c}$$

Peso igual por classe — independente da frequência.

4 Arquiteturas CNN – Transfer Learning a partir do ImageNet

DenseNet121

$$\mathbf{x}_L = H_L([\mathbf{x}_0, \dots, \mathbf{x}_{L-1}])$$

Conectividade densa

Reutiliza features de baixo nível em camadas profundas.

7M parâmetros

ResNet50

$$\mathbf{x}_{L+1} = \mathcal{F}(\mathbf{x}_L) + \mathbf{x}_L$$

Conexões residuais

Treino estável; arquitetura de referência desde 2015.

25M parâmetros

MobileNetV2

Depthwise separable

Inverted residual

Leve e eficiente; menor capacidade representacional.

3.4M parâmetros

EfficientNet-B7

$$d = \alpha^\phi, w = \beta^\phi, r = \gamma^\phi$$

Compound scaling

Maior capacidade mas sobreajuste crítico com ~1000 imagens.

66M parâmetros

Motivação comum: Transfer Learning

Com apenas 1067 imagens de treino, fine-tuning de pesos ImageNet é essencial. Treino de raiz seria instável e propenso a overfitting.

Estratégia Metodológica: Tratar o Desequilíbrio

Funções de perda ponderadas

- **Focal Loss:**
 $FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log p_t$
Penaliza exemplos fáceis; foca nas classes raras.
- **CE ponderada:** $w_c = N/(C \cdot N_c)$
Amplifica gradiente de Biliary Leaks.
- **Label smoothing** ($\epsilon = 0.1$): evita sobreconfiança.

Augmentação e inferência

- **Mixup** ($\alpha = 0.4$): interpola imagens e labels
- **TTA** (4–8 passes): média de probabilidades

Pré-processamento

- **CLAHE offline** (clipLimit=2, 8×8):
equalização adaptativa — realça estruturas subtis
- Normalização ImageNet
($\mu = [0.485, 0.456, 0.406]$)

Optimizadores

- AdamW + OneCycleLR (DenseNet)
- Differential LRs backbone/head (MobileNet)
- BN frozen nos últimos blocos (EfficientNet)

Impacto real (DenseNet, caso de estudo)

Estratégia anti-desequilíbrio

+10.2 pp

Resultados no Conjunto de Teste (n=267)

Modelo	F1 Macro	Accuracy	AUC-ROC	F1 BL
DenseNet121 v100	0.7076	0.7266	~0.92	0.667
ResNet50 v2	0.6647	0.7041	~0.89	0.552
EfficientNet-B7 RR12	0.555	0.633	~0.87	0.286
MobileNetV2 v4	~0.556	~0.620	~0.86	0.261
<i>Baseline artigo (MIQR-CC)</i>	<i>0.738</i>	—	—	—

Ganho interno: v0 → v100

0.545 $\xrightarrow{+10.2 \text{ pp}}$ 0.647 $\xrightarrow{+6.1 \text{ pp}}$ **0.7076**

vs. Baseline publicada

DenseNet v100 fica **-3.0 pp** abaixo de 0.738 (Martins et al., MIQR-CC 2025).

F1, Precisão e Recall por Classe

Classe	DenseNet121			ResNet50			EfficientNet			MobileNet		
	P	R	F1	P	R	F1	P	R	F1	P	R	F1
Biliary Leaks	0.900	0.529	0.667	0.667	0.471	0.552	0.364	0.235	0.286	0.500	0.176	0.261
Lithiasis	0.783	0.675	0.725	0.824	0.683	0.747	0.631	0.724	0.674	0.664	0.772	0.714
Normal	0.615	0.744	0.674	0.443	0.907	0.595	0.577	0.698	0.633	0.545	0.558	0.552
Stricture	0.707	0.833	0.765	0.877	0.679	0.765	0.730	0.548	0.626	0.743	0.655	0.696
Macro	0.708			0.665			0.555			0.556		

Biliary Leaks: recall máximo 9/17 (DenseNet).
Falso negativo = fuga biliar não detectada.

Stricture → **Lithiasis**: confusão sistemática.
Tratamento erróneo se mal classificado.

Matrizes de Confusão: Dois Melhores Modelos

DenseNet121 v100 F1 = 0.7076

		<i>Predição</i>			
		BL	Li	No	St
<i>Real</i>	BL [17]	9	1	3	4
	Li[123]	1	83	17	22
	No [43]	0	8	32	3
	St [84]	0	14	0	70

ResNet50 v2 F1 = 0.6647

		<i>Predição</i>			
		BL	Li	No	St
<i>Real</i>	BL [17]	8	1	8	0
	Li[123]	4	84	29	6
	No [43]	0	2	39	2
	St [84]	0	15	12	57


Padrão crítico em ambos: Stricture → Lithiasis (DenseNet: 14/84; ResNet: 15/84). Estrutura tubular da estenose visualmente semelhante a depósitos de cálculos em fluoroscopia.

DenseNet: melhor recall de Biliary Leaks (9 vs 8) e recall de Stricture (70/84 = 83%).

Grad-CAM: Interpretabilidade das Decisões


Correcto — Biliary Leaks (52.4%)

Real: Biliary_Leaks | Previsto: Biliary_Leaks (52.4%)
Grad-CAM




Incorrecto — Stricture → Lithiasis (37.4%)

Real: Stricture | Previsto: Lithiasis (37.4%)
Grad-CAM




Correcto — Lithiasis (84.8%)

Real: Lithiasis | Previsto: Lithiasis (84.8%)
Grad-CAM



Incorrecto — Biliary Leaks → Lithiasis (47.3%)

Real: Biliary_Leaks | Previsto: Lithiasis (47.3%)
Grad-CAM



Combinação DenseNet + EfficientNet

$$P_{\text{ens}}(c \mid x) = \frac{1}{2} [P_{\text{Dense}}(c \mid x) + P_{\text{Eff}}(c \mid x)]$$

- As duas arquiteturas cometem erros em padrões distintos
- A média suaviza previsões incertas
- Resultado preliminar (modelos base):
F1 > 0.55 vs. 0.545 / 0.480 isolados

Próximo passo

Ensemble **DenseNet v100 + ResNet v2**
(seria o candidato mais forte)

Por que os modelos são complementares?

- DenseNet: melhor recall BL (9/17) e Stricture (70/84)
- ResNet: melhor recall Normal (39/43) e precisão Lithiasis (0.824)
- EfficientNet: maior recall Lithiasis (0.724)

Estratégia de pesagem proposta

Modelo	Peso
DenseNet121 v100	0.50
ResNet50 v2	0.50

Pode ser otimizado no val set por classe.

Ranking Final

Pos.	Modelo	F1	Acc
1	DenseNet121 v100	0.708	0.727
2	ResNet50 v2	0.665	0.704
3	EfficientNet-B7	0.555	0.633
4	MobileNetV2	0.556	0.620
—	Baseline	0.738	—

Conclusão principal

Tratar o desequilíbrio (Focal Loss + Mixup + TTA) foi $\approx 25\times$ mais impactante do que ajustar resolução ou contraste isoladamente.

Trabalho Futuro

- **Ensemble** DenseNet v100 + ResNet v2
- **Síntese de dados** (GAN) para Biliary Leaks (recall persistente em 9/17)
- **WeightedRandomSampler** dedicado a BL
- **Vision Transformers** (ViT/Swin)
- **Validação cruzada** estratificada k-fold

Gap vs. Baseline

−3.0 pp face a Martins et al. (0.738).
Superar requer dados sintéticos ou arquiteturas de atenção espacial.

Obrigado pela atenção!

Questões?

Melhor modelo:	DenseNet121 v100 — F1 macro = 0.7076
Baseline artigo:	F1 = 0.738 (Martins et al., 2025)
Ganho interno:	+16.3 pp (v0 → v100)
Semente aleatória:	42 (reprodutível)
Código:	Repositório GitHub do grupo