

Classificação de Imagens ERCP com Redes Neurais Convolucionais Profundas

Carlos da Mota Bergueira (pg11605@alunos.uminho.pt)
Diego Jefferson Mendes Silva (pg59999@alunos.uminho.pt)
Filipa Araújo Pereira (pg42201@alunos.uminho.pt)
Rui Manuel Martins Marques Rodrigues (pg7942@alunos.uminho.pt)

Universidade do Minho, Braga, Portugal

Abstract. Este relatório apresenta um estudo comparativo de quatro arquiteturas CNN pré-treinadas para classificação multiclasse de imagens de ERCP: DenseNet121, ResNet50, MobileNetV2 e EfficientNet-B7. O objetivo principal foi maximizar o F1-score macro num cenário com forte desequilíbrio de classes, com predominância de Lithiasis e sub-representação de Biliary Leaks. Foram avaliadas mais de 20 variantes experimentais, combinando transfer learning, funções de perda ponderadas, técnicas de regularização e estratégias de inferência robusta. Os resultados mostram que a DenseNet121 v100 obteve o melhor desempenho global (F1 macro = 0.7076; accuracy = 0.7266), seguida da ResNet50 v2 (0.6647; 0.7041). EfficientNet-B7 e MobileNetV2 apresentaram desempenhos inferiores (≈ 0.555), associados a sobreajuste e menor capacidade de adaptação, respetivamente. A análise por classe confirma que o tratamento explícito do desequilíbrio (Focal Loss, class weights, Mixup e TTA) teve impacto superior ao de ajustes isolados de pré-processamento. Os resultados reforçam a adequação de abordagens orientadas a classes minoritárias em tarefas médicas de risco elevado e apontam o ensemble como via promissora de melhoria.

Keywords: CNN · transfer learning · ERCP · F1 macro · desequilíbrio de classes · ensemble

1 Introdução

1.1 Problema e Dataset

O dataset MIQR-CC [1] consiste em imagens de ERCP classificadas em quatro categorias clínicas: Biliary Leaks, Lithiasis, Normal e Stricture. A distribuição é fortemente desequilibrada, com predominância de Lithiasis e sub-representação de Biliary Leaks.

A métrica principal é o F1-score macro:

$$F_1^{\text{macro}} = \frac{1}{C} \sum_{c=1}^C \frac{2P_c R_c}{P_c + R_c} \quad (1)$$

Esta métrica penaliza fortemente modelos que ignoram classes minoritárias, mesmo quando a accuracy global é elevada.

Table 1: Distribuição das classes por split.

Split	Total	Biliary Leaks	Lithiasis	Normal	Stricture
Treino	1067	110 (10.3%)	505 (47.3%)	197 (18.5%)	255 (23.9%)
Validação	234	24	98	59	53
Teste	267	17	123	43	84

1.2 Motivação para Transfer Learning

Todos os modelos foram inicializados com pesos ImageNet. Dado o tamanho do conjunto de treino (1067 imagens), o treino de raiz seria instável e propenso a sobreajuste. O transfer learning fornece descritores visuais genéricos que aceleram convergência e reduzem a necessidade de dados anotados [8].

2 Arquiteturas Estudadas

2.1 DenseNet121

Na DenseNet, cada camada recebe a concatenação das ativações anteriores:

$$\mathbf{x}_L = H_L([\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{L-1}]) \quad (2)$$

Esta conectividade densa favorece reutilização de características de baixo nível e propagação de gradiente robusta [3].

2.2 ResNet50

A ResNet aprende funções residuais:

$$\mathbf{x}_{L+1} = \mathcal{F}(\mathbf{x}_L, \{W_i\}) + \mathbf{x}_L \quad (3)$$

As conexões de atalho mitigam vanishing gradients e estabilizam o treino em redes profundas [2].

2.3 MobileNetV2

A MobileNetV2 usa blocos inverted residual com convoluções depthwise separable, reduzindo custo computacional de $O(D_k^2 MN)$ para $O(D_k^2 M + MN)$, com menor capacidade representacional face a arquiteturas maiores [6].

2.4 EfficientNet-B7

A EfficientNet aplica compound scaling conjunto de profundidade, largura e resolução:

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi \quad (4)$$

Embora muito expressiva, a variante B7 é sensível a batch size e ao regime de fine-tuning parcial [9].

3 Progressão Experimental por Arquitetura

3.1 DenseNet121

Foram avaliadas sete versões, de v0 a v101. O salto principal ocorreu entre v3 e v99 após introdução explícita de técnicas para classes minoritárias (Focal Loss + CE ponderada, Mixup, TTA e threshold tuning), elevando o F1 macro de 0.545 (v0) para 0.647 (v99). A melhor configuração foi a v100/v101 com F1 macro 0.7076 e accuracy 0.7266.

3.2 ResNet50

Três versões finais foram comparadas. A v2 (pipeline genérico + Dropout 0.3) atingiu F1 macro 0.6647 e accuracy 0.7041, superando baseline e variantes com pré-processamento especializado.

3.3 MobileNetV2

O desempenho variou entre 0.306 e 0.556. O melhor resultado observado foi com CLAHE offline (v4, F1 $\approx$ 0.556). A versão v7 explorou differential learning rates, Mixup e label smoothing, mas manteve desempenho na mesma ordem.

3.4 EfficientNet-B7

A melhor versão (RR12) obteve F1 macro 0.555 e accuracy 0.633, após congelamento de BatchNorm e fine-tuning parcial dos últimos blocos. O padrão dominante foi sobreajuste severo nas variantes iniciais.

4 Comparativo Detalhado

4.1 Configuração dos Melhores Modelos

Para garantir reprodutibilidade, todos os modelos fixaram a semente aleatória em 42 (`torch.manual_seed`, `numpy.random.seed` e `random.seed`), e o código completo está disponível no repositório do grupo.

4.2 Resultados Globais no Teste

O melhor modelo deste trabalho (DenseNet121 v100) ficou 3.0 pontos percentuais abaixo da baseline reportada no artigo de referência (F1 macro = 0.738), mas representa ganho de 16.3 pontos percentuais face ao baseline interno (v0).

Table 2: Resumo das melhores configurações por arquitetura.

Parâmetro	DenseNet121 v100	ResNet50 v2	EfficientNet-B7 RR12	MobileNetV2 v4
Backbone	DenseNet121	ResNet50	EfficientNet-B7	MobileNetV2
Resolução	256×256	512×512	512×512	224×224
Batch size	8	4	16	32
Otimizador	AdamW	Adam	AdamW	AdamW
LR backbone	1e-4	1e-4	3e-5	1e-5/5e-5
LR cabeça	1e-4	1e-4	3e-4	1e-3
Scheduler	OneCycleLR	CosineAnnealingLR	Warm-up + Cosine	Warm-up + Cosine
Perda	0.5 Focal + 0.5 CE pond.	Focal Loss	CE ponderada	CE pond. + LS
Mixup	Sim ($\alpha = 0.4$)	Não	Não	Sim ($\alpha = 0.2$)
TTA	4 variantes	Não	8 passes	Não
Pré-processamento	CLAHE offline	Pipeline genérico	CLAHE + BONE	CLAHE offline

Table 3: Resultados globais no conjunto de teste (267 amostras). AUC-ROC estimado via One-vs-Rest macro. BL = Biliary Leaks.

Modelo	F1 Macro	Accuracy	AUC-ROC macro	F1 BL
DenseNet121 v100	0.7076	0.7266	~0.92	0.667
ResNet50 v2	0.6647	0.7041	~0.89	0.552
EfficientNet-B7 RR12	0.555	0.633	~0.87	0.286
MobileNetV2 v4	~0.556	~0.620	~0.86	0.261
Baseline artigo (MIQR-CC)	0.738	–	–	–

4.3 Matrizes de Confusão dos Melhores Modelos

DenseNet121 v100 ($F1 = 0.7076$).

	Pred BL	Pred Li	Pred No	Pred St	
Real BL	[17]	9	1	3	4
Real Li	[123]	1	83	17	22
Real No	[43]	0	8	32	3
Real St	[84]	0	14	0	70

ResNet50 v2 ($F1 = 0.6647$).

	Pred BL	Pred Li	Pred No	Pred St	
Real BL	[17]	8	1	8	0
Real Li	[123]	4	84	29	6
Real No	[43]	0	2	39	2
Real St	[84]	0	15	12	57

EfficientNet-B7 RR12 ($F1 = 0.555$, sem TTA).

	Pred BL	Pred Li	Pred No	Pred St	
Real BL	[17]	4	7	6	0
Real Li	[123]	2	89	15	17
Real No	[43]	1	12	30	0
Real St	[84]	4	33	1	46

MobileNetV2 v4 ($F1 = 0.5558$).

	Pred BL	Pred Li	Pred No	Pred St	
Real BL	[17]	3	5	9	0
Real Li	[123]	1	95	9	18
Real No	[43]	1	17	24	1
Real St	[84]	1	26	2	55

4.4 Análise por Classe

A Tabela 4 decompõe precisão, recall e F1 por classe para os quatro melhores modelos, calculados directamente das matrizes de confusão.

Table 4: Precisão (P), Recall (R) e F1 por classe no conjunto de teste. Valores em negrito indicam o melhor F1 por célula.

Classe	DenseNet121 v100			ResNet50 v2			EfficientNet-B7 RR12			MobileNetV2 v4		
	P	R	F1	P	R	F1	P	R	F1	P	R	F1
Biliary Leaks	0.900	0.529	0.667	0.667	0.471	0.552	0.364	0.235	0.286	0.500	0.176	0.261
Lithiasis	0.783	0.675	0.725	0.824	0.683	0.747	0.631	0.724	0.674	0.664	0.772	0.714
Normal	0.615	0.744	0.674	0.443	0.907	0.595	0.577	0.698	0.633	0.545	0.558	0.552
Stricture	0.707	0.833	0.765	0.877	0.679	0.765	0.730	0.548	0.626	0.743	0.655	0.696
Macro avg	—	—	0.708	—	—	0.665	—	—	0.555	—	—	0.556

Biliary Leaks. A DenseNet v100 apresentou o melhor compromisso de precisão-recall nesta classe crítica ($F1 = 0.667$). Mesmo assim, os falsos negativos permanecem clinicamente relevantes.

Lithiasis. A ResNet v2 obteve o melhor F1 (0.747), favorecida pela classe maioritária e por convergência estável do classificador com Dropout.

Normal. A ResNet v2 maximizou recall (39/43), ao custo de menor precisão. A DenseNet teve comportamento mais equilibrado.

Stricture. DenseNet v100 e ResNet v2 empataram em $F1 = 0.765$ por mecanismos distintos: maior recall na DenseNet e maior precisão na ResNet.

Implicações clínicas dos erros. Erros em Biliary Leaks têm maior gravidade potencial (risco de atraso em diagnóstico de fuga biliar). Confusões Stricture→Lithiasis podem induzir decisões terapêuticas inadequadas. Em contraste, falsos positivos de Lithiasis tendem a ter menor risco imediato, embora aumentem exames adicionais.

Table 5: Impacto de decisões metodológicas na DenseNet.

Decisão	Impacto no F1 Macro
Redução de resolução 512→224	-0.032
CLAHE em runtime (+512)	+0.004
Estratégia anti-desequilíbrio (v99)	+0.102
CLAHE offline + AMP + 256 px	+0.061

4.5 Fatores Determinantes

Os resultados indicam que o maior ganho veio de decisões de treino orientadas a classes minoritárias, não de alterações isoladas de resolução ou contraste.

5 Técnicas Transversais

5.1 Desequilíbrio de Classes e Regularização

Foram usadas Focal Loss [4], class weights na cross-entropy, WeightedRandomSampler (EfficientNet), label smoothing, Dropout, Mixup [10] e gradient clipping.

5.2 Inferência Robusta e Pré-processamento

A inferência incluiu Test-Time Augmentation e threshold tuning por classe. No pré-processamento destacaram-se CLAHE [5], normalização ImageNet, pseudo-color BONE e, em variantes específicas, ROI anatómica.

5.3 Otimizadores e Schedulers


Os regimes mais eficazes combinaram AdamW com OneCycleLR ou warm-up linear seguido de cosine annealing. Differential learning rates foram importantes sobretudo para MobileNetV2.

5.4 Interpretabilidade com Grad-CAM


Foi aplicado Grad-CAM [7] para verificar regiões de atenção:

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right), \quad \alpha_k^c = \frac{1}{Z} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k} \quad (5)$$

As ativações focaram áreas anatómicas relevantes (ductos e estenoses), dando suporte qualitativo às decisões dos modelos. Cada visualização apresenta, da esquerda para a direita, a imagem original, o mapa de calor Grad-CAM e o overlay combinado. Títulos a verde indicam predição correcta; a vermelho, predição incorrecta.




(a) Biliary_Leaks → Biliary_Leaks (52.4%) — correcta.




(b) Biliary_Leaks → Lithiasis (47.3%) — incorrecta: heatmap activa o ducto principal, região morfológicamente semelhante a cálculos.

Fig. 1: Grad-CAM — Biliary_Leaks (dois exemplos do conjunto de teste).




(a) Lithiasis → Lithiasis (84.8%) — correcta: activação concentrada na zona de deposição de cálculos, com alta confiança.

Fig. 2: Grad-CAM — Lithiasis (exemplo de classificação correcta).



(a) Normal $\rightarrow$ Normal (57.9%) — correcta: heatmap difuso, sem foco em nenhuma região patológica.



(b) Normal $\rightarrow$ Lithiasis (52.2%) — incorrecta: o modelo activa uma região periférica semelhante à morfologia de cálculos.

Fig. 3: Grad-CAM — Normal (dois exemplos do conjunto de teste).




Fig. 4: Grad-CAM — Stricture (dois exemplos do conjunto de teste).

6 Abordagem Ensemble

Foi implementado um ensemble por soft voting entre DenseNet121 e EfficientNet-B7:

$$P_{\text{ensemble}}(c \mid x) = \frac{1}{M} \sum_{m=1}^M P_m(c \mid x) \quad (6)$$

Resultados preliminares com modelos base indicaram melhoria ligeira face aos modelos isolados (F1 macro superior a 0.55). A combinação de versões mais fortes (DenseNet v99/v100 com EfficientNet melhorada) mantém-se como direção de continuação.

Table 6: Ranking final das arquiteturas.

Pos.	Arquitetura	Melhor versão	F1 Macro	Accuracy
1	DenseNet121	v100/v101	0.7076	0.7266
2	ResNet50	v2	0.6647	0.7041
3	EfficientNet-B7	RR12	~0.556	~0.633
4	MobileNetV2	v4	~0.556	~0.620

7 Síntese e Conclusões

7.1 Ranking Final

7.2 Conclusão Principal

O tratamento explícito do desequilíbrio de classes foi o fator mais determinante no desempenho final. A DenseNet121 combinou de forma mais eficaz Focal Loss, class weighting, Mixup e TTA, alcançando F1 macro = 0.7076 (+16.3 pp face ao baseline interno, v0). O gap de 3.0 pp face à baseline publicada [1] (F1 = 0.738) indica que superar esse valor requereria dados sintéticos adicionais para Biliary Leaks ou arquiteturas de atenção espacial (e.g. Vision Transformers), não exploradas neste trabalho.

7.3 Trabalho Futuro

As principais direções futuras são: (i) reforço de recall em Biliary Leaks com amostragem ponderada e síntese de dados, (ii) validação cruzada estratificada para estimativa robusta da variância, e (iii) ensemble entre os dois melhores modelos individuais (DenseNet v100 + ResNet v2).

References

1. Martins, M.C. et al.: Curated endoscopic retrograde cholangiopancreatography images dataset (MIQR-CC). Figshare (2025). <https://doi.org/10.6084/m9.figshare.31079236>
2. He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: CVPR (2016)
3. Huang, G., Liu, Z., Van Der Maaten, L., Weinberger, K.Q.: Densely connected convolutional networks. In: CVPR (2017)
4. Lin, T.-Y., Goyal, P., Girshick, R., He, K., Dollár, P.: Focal loss for dense object detection. In: ICCV (2017)
5. Pizer, S.M. et al.: Adaptive histogram equalization and its variations. CVGIP (1987)
6. Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., Chen, L.-C.: MobileNetV2: Inverted residuals and linear bottlenecks. In: CVPR (2018)
7. Selvaraju, R.R. et al.: Grad-CAM: Visual explanations from deep networks. In: ICCV (2017)

8. Tajbakhsh, N. et al.: Convolutional neural networks for medical image analysis. *IEEE Transactions on Medical Imaging* (2016)
9. Tan, M., Le, Q.: EfficientNet: Rethinking model scaling for convolutional neural networks. In: *ICML* (2019)
10. Zhang, H., Cissé, M., Dauphin, Y.N., Lopez-Paz, D.: Mixup: Beyond empirical risk minimization. In: *ICLR* (2018)