

Classificação de Imagens ERCP com Redes Neurais Convolucionais Profundas

Carlos da Mota Bergueira (pg11605@alunos.uminho.pt)
Diego Jefferson Mendes Silva (pg59999@alunos.uminho.pt)
Filipa Araújo Pereira (pg42201@alunos.uminho.pt)
Rui Manuel Martins Marques Rodrigues (pg7942@alunos.uminho.pt)

Universidade do Minho, Braga, Portugal

Abstract. Este relatório apresenta um estudo comparativo de quatro arquiteturas CNN pré-treinadas para classificação multiclasse de imagens de ERCP: DenseNet121, ResNet50, MobileNetV2 e EfficientNet-B7. O objetivo principal foi maximizar o F1-score macro num cenário com forte desequilíbrio de classes, com predominância de Lithiasis e sub-representação de Biliary Leaks. Foram avaliadas mais de 20 variantes experimentais, combinando transfer learning, funções de perda ponderadas, técnicas de regularização e estratégias de inferência robusta. Os resultados mostram que a DenseNet121 obteve o melhor desempenho global (F1 macro = 0.7076; accuracy = 0.7266), seguida da ResNet50 (0.6647; 0.7041). EfficientNet-B7 e MobileNetV2 apresentaram desempenhos inferiores (≈ 0.555), associados a sobreajuste e menor capacidade de adaptação, respetivamente. A análise por classe confirma que o tratamento explícito do desequilíbrio (Focal Loss, class weights, Mixup e TTA) teve impacto superior ao de ajustes isolados de pré-processamento. Os resultados reforçam a adequação de abordagens orientadas a classes minoritárias em tarefas médicas de risco elevado e apontam o ensemble como via promissora de melhoria.

Keywords: CNN · transfer learning · ERCP · F1 macro · desequilíbrio de classes · ensemble

1 Introdução

1.1 Problema e Dataset

O dataset MIQR-CC [1] consiste em imagens de ERCP classificadas em quatro categorias clínicas: Biliary Leaks, Lithiasis, Normal e Stricture. A distribuição é fortemente desequilibrada, com predominância de Lithiasis e sub-representação de Biliary Leaks.

A métrica principal é o F1-score macro:

$$F_1^{\text{macro}} = \frac{1}{C} \sum_{c=1}^C \frac{2P_c R_c}{P_c + R_c} \quad (1)$$

Esta métrica penaliza fortemente modelos que ignoram classes minoritárias, mesmo quando a accuracy global é elevada.

Table 1: Distribuição das classes por split.

Split	Total	Biliary Leaks	Lithiasis	Normal	Stricture
Treino	1067	110 (10.3%)	505 (47.3%)	197 (18.5%)	255 (23.9%)
Validação	234	24	98	59	53
Teste	267	17	123	43	84

1.2 Motivação para Transfer Learning

Todos os modelos foram inicializados com pesos ImageNet. Dado o tamanho do conjunto de treino (1067 imagens), o treino de raiz seria instável e propenso a sobreajuste. O transfer learning fornece descritores visuais genéricos que aceleram convergência e reduzem a necessidade de dados anotados [8].

2 Arquiteturas Estudadas

2.1 DenseNet121

Na DenseNet, cada camada recebe a concatenação das ativações anteriores:

$$\mathbf{x}_L = H_L([\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{L-1}]) \quad (2)$$

Esta conectividade densa favorece reutilização de características de baixo nível e propagação de gradiente robusta [3].

2.2 ResNet50

A ResNet aprende funções residuais:

$$\mathbf{x}_{L+1} = \mathcal{F}(\mathbf{x}_L, \{W_i\}) + \mathbf{x}_L \quad (3)$$

As conexões de atalho mitigam vanishing gradients e estabilizam o treino em redes profundas [2].

2.3 MobileNetV2

A MobileNetV2 usa blocos inverted residual com convoluções depthwise separable, reduzindo custo computacional de $O(D_k^2 MN)$ para $O(D_k^2 M + MN)$, com menor capacidade representacional face a arquiteturas maiores [6].

2.4 EfficientNet-B7

A EfficientNet aplica compound scaling conjunto de profundidade, largura e resolução:

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi \quad (4)$$

Embora muito expressiva, a variante B7 é sensível a batch size e ao regime de fine-tuning parcial [9].

3 Progressão Experimental por Arquitetura

3.1 DenseNet121

Foram avaliadas sete versões. O salto principal ocorreu após a introdução explícita de técnicas orientadas a classes minoritárias (Focal Loss + CE ponderada, Mixup, TTA e threshold tuning), elevando o F1 macro de 0.545 para 0.647. A adição de CLAHE offline e resolução 256×256 (v100) representou um ganho adicional de 6.1 pp, culminando em F1 macro 0.7076 e accuracy 0.7266 no conjunto de teste.




Fig. 1: Curvas de treino da DenseNet121 (melhor configuração, v100): F1-score macro e função de perda em treino e validação ao longo das épocas.

A Figura 1 revela um padrão de convergência estável e progressivo. O F1 de treino sobe monotonicamente de ≈ 0.17 para ≈ 0.63 ao longo de 46 épocas, enquanto o F1 de validação acompanha com um desfasamento moderado, atingindo

≈ 0.51 e estabilizando a partir da época 30. A perda de treino decresce de forma contínua ($\approx 1.37 \rightarrow 0.82$) e a perda de validação apresenta apenas uma ligeira subida residual ($\approx 1.38 \rightarrow 1.28$), sem divergência — indicador de ausência de sobreajuste severo. O diferencial treino-validação em F1 (≈ 0.12) é consistente com o nível de regularização aplicado (Mixup $\alpha = 0.4$, Dropout, label smoothing) e com o tamanho do conjunto de treino. O salto observado no F1 de validação final face ao valor durante o treino ($\approx 0.51 \rightarrow 0.71$) deve-se ao TTA e ao threshold tuning aplicados apenas na fase de avaliação, confirmando a importância destas técnicas de inferência robusta.

3.2 ResNet50

Quatro versões foram comparadas. A melhor configuração introduziu CLAHE offline, pré-processamento guiado pelo domínio (ROI circular, ScaleIntensityRangePercentiles), Dropout(0.3) no classificador e data augmentation conservadora, atingindo F1 macro 0.6647 e accuracy 0.7041 no conjunto de teste.




Fig. 2: Curvas de treino da ResNet50 (melhor configuração): AUC-ROC de validação, F1-score macro, accuracy e função de perda ao longo das épocas.

A Figura 2 mostra um padrão oscilatório ao longo de 50 épocas, característico do scheduler CosineAnnealingLR em presença de desequilíbrio de classes. O AUC de validação sobe de ≈ 0.55 para ≈ 0.80 com crescimento mais marcado até à época 20, depois estabilizando com oscilações de ± 0.05 . O F1 de treino sobe gradualmente de ≈ 0.21 para ≈ 0.62 , enquanto o F1 de validação oscila entre 0.35 e 0.65, terminando em ≈ 0.62 . Esta variância elevada na validação reflete a sensibilidade da métrica macro ao comportamento nas classes minoritárias: pequenas variações na fronteira de decisão de Biliary Leaks produzem saltos amplos no F1 macro. A perda de treino decresce de forma regular ($\approx 0.8 \rightarrow 0.32$) ao passo que a perda de validação oscila sem tendência de divergência clara, confirmando a adequação do Dropout como regularizador. A accuracy de validação ($\approx 0.55\text{--}0.60$) ficou abaixo da de treino ($\approx 0.65\text{--}0.73$), desfasamento esperado num cenário com distribuição de classes diferente entre splits.

3.3 MobileNetV2

O desempenho variou entre 0.306 e 0.556. O melhor resultado foi obtido com CLAHE offline, imagens RGB com normalização ImageNet e learning rates diferenciados por grupo de camadas, alcançando F1 macro 0.5558 e accuracy 0.6629 no conjunto de teste.




Fig. 3: Curvas de treino da MobileNetV2: sobreajuste severo após desbloqueio do backbone na fase 2 de fine-tuning.

A Figura 3 ilustra o fenómeno de sobreajuste catastrófico observado nas variantes com fine-tuning faseado. Após aproximadamente 10 épocas com o backbone congelado (fase 1), o desbloqueio da totalidade dos pesos (fase 2) provocou memorização rápida do conjunto de treino: o F1 de treino convergiu para ≈ 1.0 e a accuracy de treino para 1.0 em cerca de 15 épocas, enquanto o F1 de validação estabilizou em ≈ 0.40 – 0.50 e a perda de validação divergiu explosivamente para ≈ 5.0 . Este padrão evidencia que a MobileNetV2, com capacidade representacional mais limitada que as restantes arquiteturas, é incapaz de generalizar sob esta estratégia de fine-tuning: a transição abrupta de backbone congelado para completamente desbloqueado, sem warm-up adequado, causa atualização incontrollada dos pesos em camadas que já tinham aprendido características genéricas do ImageNet. A solução adoptada nas versões v6/v7 — differential learning rates sem fase de congelamento — visou precisamente mitigar este comportamento.

3.4 EfficientNet-B7

A melhor versão (RR12) obteve F1 macro 0.5557 e accuracy 0.6217 no conjunto de teste, com congelamento de BatchNorm e fine-tuning parcial dos últimos blocos. O padrão dominante nas variantes iniciais foi sobreajuste precoce.




Fig. 4: Curvas de treino da EfficientNet-B7: rápida memorização do conjunto de treino com degradação simultânea da validação.

A Figura 4 documenta o comportamento de sobreajuste precoce da EfficientNet-B7. O F1 de treino atinge ≈ 0.90 e a accuracy de treino ≈ 0.93 em apenas 3–4 épocas, enquanto o AUC de validação sobe rapidamente para ≈ 0.82 na época 2 e depois recua para ≈ 0.76 . O F1 de validação atinge um máximo de ≈ 0.55 na época 2 e regride para ≈ 0.45 , e a perda de validação aumenta de ≈ 0.125 para ≈ 0.190 à medida que a perda de treino colapsa para ≈ 0.025 . O early stopping interrompeu o treino na época 11, limitando a degradação mas também o es-

paço de exploração. Esta dinâmica é consequência da elevada capacidade do EfficientNet-B7 (≈ 66 M parâmetros): a rede memoriza as 1067 imagens de treino em poucos passos de gradiente, não havendo regularização suficiente para forçar a aprendizagem de representações generalizáveis. A elevação do AUC para 0.87 no teste final — acima do F1 macro — indica que o modelo preserva alguma capacidade discriminativa probabilística, aproveitada parcialmente pelo TTA de 8 passes na avaliação final.

4 Comparativo Detalhado

4.1 Configuração dos Melhores Modelos

Para garantir reprodutibilidade, todos os modelos fixaram a semente aleatória em 42 (`torch.manual_seed`, `numpy.random.seed` e `random.seed`), e o código completo está disponível no repositório do grupo.

Table 2: Resumo das melhores configurações por arquitetura.

Parâmetro	DenseNet121	ResNet50	EfficientNet-B7	MobileNetV2
Backbone	DenseNet121	ResNet50	EfficientNet-B7	MobileNetV2
Resolução	256×256	512×512	512×512	224×224
Batch size	8	4	16	32
Otimizador	AdamW	Adam	AdamW	AdamW
LR backbone	$1e-4$	$1e-4$	$3e-5$	$1e-5/5e-5$
LR cabeça	$1e-4$	$1e-4$	$3e-4$	$1e-3$
Scheduler	OneCycleLR	CosineAnnealingLR	Warm-up + Cosine	Warm-up + Cosine
Perda	0.5 Focal + 0.5 CE pond.	Focal Loss	CE ponderada	CE pond. + LS
Mixup	Sim ($\alpha = 0.4$)	Não	Não	Sim ($\alpha = 0.2$)
TTA	4 variantes	Não	8 passes	Não
Pré-processamento	CLAHE offline	Pipeline genérico	CLAHE + BONE	CLAHE offline

4.2 Resultados Globais no Teste

Table 3: Resultados globais no conjunto de teste (267 amostras). AUC-ROC estimado via One-vs-Rest macro. BL = Biliary Leaks.

Modelo	F1 Macro	Accuracy	AUC-ROC macro	F1 BL
DenseNet121	0.7076	0.7266	~ 0.92	0.667
ResNet50	0.6647	0.7041	~ 0.89	0.552
EfficientNet-B7	0.5557	0.6217	~ 0.87	0.286
MobileNetV2	~ 0.5558	~ 0.6629	~ 0.86	0.261
Baseline artigo (MIQR-CC)	0.738	—	—	—

O melhor modelo deste trabalho (DenseNet121) ficou 3.0 pontos percentuais abaixo da baseline reportada no artigo de referência (F1 macro = 0.738), mas representa ganho de 16.3 pontos percentuais face ao baseline interno (v0).

4.3 Matrizes de Confusão dos Melhores Modelos

DenseNet121 ($F1 = 0.7076$).

	Pred BL	Pred Li	Pred No	Pred St	
Real BL	[17]	9	1	3	4
Real Li	[123]	1	83	17	22
Real No	[43]	0	8	32	3
Real St	[84]	0	14	0	70

ResNet50 ($F1 = 0.6647$).

	Pred BL	Pred Li	Pred No	Pred St	
Real BL	[17]	8	1	8	0
Real Li	[123]	4	84	29	6
Real No	[43]	0	2	39	2
Real St	[84]	0	15	12	57

EfficientNet-B7 ($F1 = 0.555$, sem TTA).

	Pred BL	Pred Li	Pred No	Pred St	
Real BL	[17]	4	7	6	0
Real Li	[123]	2	89	15	17
Real No	[43]	1	12	30	0
Real St	[84]	4	33	1	46

MobileNetV2 ($F1 = 0.5558$).

	Pred BL	Pred Li	Pred No	Pred St	
Real BL	[17]	3	5	9	0
Real Li	[123]	1	95	9	18
Real No	[43]	1	17	24	1
Real St	[84]	1	26	2	55

4.4 Análise por Classe

A Tabela 4 decompõe precisão, recall e F1 por classe para os quatro melhores modelos, calculados directamente das matrizes de confusão.

Biliary Leaks. A DenseNet121 apresentou o melhor compromisso de precisão-recall nesta classe crítica ($F1 = 0.667$). Mesmo assim, os falsos negativos permanecem clinicamente relevantes.

Table 4: Precisão (P), Recall (R) e F1 por classe no conjunto de teste. Valores em negrito indicam o melhor F1 por célula.

Classe	DenseNet121			ResNet50			EfficientNet-B7			MobileNetV2		
	P	R	F1	P	R	F1	P	R	F1	P	R	F1
Biliary Leaks	0.900	0.529	0.667	0.667	0.471	0.552	0.364	0.235	0.286	0.500	0.176	0.261
Lithiasis	0.783	0.675	0.725	0.824	0.683	0.747	0.631	0.724	0.674	0.664	0.772	0.714
Normal	0.615	0.744	0.674	0.443	0.907	0.595	0.577	0.698	0.633	0.545	0.558	0.552
Stricture	0.707	0.833	0.765	0.877	0.679	0.765	0.730	0.548	0.626	0.743	0.655	0.696
Macro avg	—	—	0.708	—	—	0.665	—	—	0.555	—	—	0.556

Lithiasis. A ResNet50 obteve o melhor F1 (0.747), favorecida pela classe majoritária e por convergência estável do classificador com Dropout.

Normal. A ResNet50 maximizou recall (39/43), ao custo de menor precisão. A DenseNet121 teve comportamento mais equilibrado.

Stricture. DenseNet121 e ResNet50 empataram em $F1 = 0.765$ por mecanismos distintos: maior recall na DenseNet121 e maior precisão na ResNet50.

Implicações clínicas dos erros. Erros em Biliary Leaks têm maior gravidade potencial (risco de atraso em diagnóstico de fuga biliar). Confusões Stricture→Lithiasis podem induzir decisões terapêuticas inadequadas. Em contraste, falsos positivos de Lithiasis tendem a ter menor risco imediato, embora aumentem exames adicionais.

4.5 Fatores Determinantes

Os resultados indicam que o maior ganho veio de decisões de treino orientadas a classes minoritárias, não de alterações isoladas de resolução ou contraste.

Table 5: Impacto de decisões metodológicas na DenseNet.

Decisão	Impacto no F1 Macro
Redução de resolução 512→224	-0.032
CLAHE em runtime (+512)	+0.004
Estratégia anti-desequilíbrio	+0.102
CLAHE offline + AMP + 256 px	+0.061

5 Técnicas Transversais

5.1 Desequilíbrio de Classes e Regularização

Foram usadas Focal Loss [4], class weights na cross-entropy, WeightedRandomSampler (EfficientNet), label smoothing, Dropout, Mixup [10] e gradient clipping.

5.2 Inferência Robusta e Pré-processamento

A inferência incluiu Test-Time Augmentation e threshold tuning por classe. No pré-processamento destacaram-se CLAHE [5], normalização ImageNet, pseudo-color BONE e, em variantes específicas, ROI anatómica.

5.3 Otimizadores e Schedulers


Os regimes mais eficazes combinaram AdamW com OneCycleLR ou warm-up linear seguido de cosine annealing. Differential learning rates foram importantes sobretudo para MobileNetV2.

5.4 Interpretabilidade com Grad-CAM


Foi aplicado Grad-CAM [7] para verificar regiões de atenção:

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right), \quad \alpha_k^c = \frac{1}{Z} \sum_{i,j} \frac{\partial y^c}{\partial A_{ij}^k} \quad (5)$$

As ativações focaram áreas anatómicas relevantes (ductos e estenoses), dando suporte qualitativo às decisões dos modelos. Cada visualização apresenta, da esquerda para a direita, a imagem original, o mapa de calor Grad-CAM e o overlay combinado. Títulos a verde indicam predição correcta; a vermelho, predição incorrecta.




(a) Biliary_Leaks $\rightarrow$ Biliary_Leaks (52.4%) — correcta.




(b) Biliary_Leaks $\rightarrow$ Lithiasis (47.3%) — incorrecta: heatmap activa o ducto principal, região morfológicamente semelhante a cálculos.

Fig. 5: Grad-CAM — Biliary_Leaks (dois exemplos do conjunto de teste).




(a) Lithiasis $\rightarrow$ Lithiasis (84.8%) — correcta: activação concentrada na zona de deposição de cálculos, com alta confiança.

Fig. 6: Grad-CAM — Lithiasis (exemplo de classificação correcta).




(a) Normal $\rightarrow$ Normal (57.9%) — correcta: heatmap difuso, sem foco em nenhuma região patológica.




(b) Normal $\rightarrow$ Lithiasis (52.2%) — incorrecta: o modelo activa uma região periférica semelhante à morfologia de cálculos.

Fig. 7: Grad-CAM — Normal (dois exemplos do conjunto de teste).



(a) Stricture → Stricture (69.6%) — correcta: activação localizada na zona de estenose do ducto biliar.



(b) Stricture → Lithiasis (37.4%) — incorrecta: heatmap activa uma estrutura tubular que o modelo interpreta como presença de cálculo, confirmando a confusão sistemática Stricture/Lithiasis.

Fig. 8: Grad-CAM — Stricture (dois exemplos do conjunto de teste).

6 Abordagem Ensemble

Foi implementado um ensemble por soft voting entre DenseNet121 e EfficientNet-B7:

$$P_{\text{ensemble}}(c \mid x) = \frac{1}{M} \sum_{m=1}^M P_m(c \mid x) \quad (6)$$

Resultados preliminares com modelos base indicaram melhoria ligeira face aos modelos isolados (F1 macro superior a 0.55). A combinação de versões mais fortes (DenseNet121 com EfficientNet-B7 melhorada) mantém-se como direcção de continuação.

Table 6: Ranking final das arquiteturas.

Pos.	Arquitetura	F1 Macro	Accuracy
1	DenseNet121	0.7076	0.7266
2	ResNet50	0.6647	0.7041
3	EfficientNet-B7	~0.556	~0.633
4	MobileNetV2	~0.556	~0.620

7 Síntese e Conclusões

7.1 Ranking Final

7.2 Conclusão Principal

O tratamento explícito do desequilíbrio de classes foi o fator mais determinante no desempenho final. A DenseNet121 combinou de forma mais eficaz Focal Loss, class weighting, Mixup e TTA, alcançando F1 macro = 0.7076 (+16.3 pp face ao baseline interno, v0). O gap de 3.0 pp face à baseline publicada [1] (F1 = 0.738) indica que superar esse valor requereria dados adicionais para Biliary Leaks ou arquiteturas de atenção espacial (e.g. Vision Transformers), não exploradas neste trabalho.

7.3 Trabalho Futuro

As principais direções futuras são: (i) reforço de recall em Biliary Leaks com amostragem ponderada e síntese de dados, (ii) validação cruzada estratificada para estimativa robusta da variância, e (iii) ensemble entre os dois melhores modelos individuais (DenseNet121 + ResNet50).

References

1. Martins, M.C. et al.: Curated endoscopic retrograde cholangiopancreatography images dataset (MIQR-CC). Figshare (2025). <https://doi.org/10.6084/m9.figshare.31079236>
2. He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: CVPR (2016)
3. Huang, G., Liu, Z., Van Der Maaten, L., Weinberger, K.Q.: Densely connected convolutional networks. In: CVPR (2017)
4. Lin, T.-Y., Goyal, P., Girshick, R., He, K., Dollár, P.: Focal loss for dense object detection. In: ICCV (2017)
5. Pizer, S.M. et al.: Adaptive histogram equalization and its variations. CVGIP (1987)
6. Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., Chen, L.-C.: MobileNetV2: Inverted residuals and linear bottlenecks. In: CVPR (2018)
7. Selvaraju, R.R. et al.: Grad-CAM: Visual explanations from deep networks. In: ICCV (2017)

8. Tajbakhsh, N. et al.: Convolutional neural networks for medical image analysis. *IEEE Transactions on Medical Imaging* (2016)
9. Tan, M., Le, Q.: EfficientNet: Rethinking model scaling for convolutional neural networks. In: *ICML* (2019)
10. Zhang, H., Cissé, M., Dauphin, Y.N., Lopez-Paz, D.: Mixup: Beyond empirical risk minimization. In: *ICLR* (2018)